

ECE228 — Physics-Informed Neural Networks

隊員入門導覽文件 (Team Onboarding Guide)

Traditional Chinese · 2026 Spring · ECE228 PINN Team

0. 術語速查 (Glossary)

下面列了常用術語的白話解釋，邊讀邊查就好——全文都保留英文原文。

術語	縮寫	說明
物理背景		
Navier–Stokes Equations	N-S	描述不可壓縮黏性流體運動的偏微分方程組，是本專案所有物理約束的來源。
Reynolds Number	Re	無因次數，描述慣性力與黏性力的比值。Re = 100 時，圓柱後方產生週期性 Kármán vortex street。
Kármán Vortex Street		流體繞過圓柱後方出現的交替脫落漩渦結構，是本專案模擬的物理現象。
Vorticity		描述流體旋轉強度的物理量 ($\partial v/\partial x - \partial u/\partial y$)，視覺化時用來呈現渦街結構。
Computational Fluid Dynamics	CFD	用數值方法（有限元素、有限體積）在 mesh 上求解流體方程式的傳統工程工具（如 Fluent、OpenFOAM）。
神經網路基礎		
Multilayer Perceptron	MLP	最基本的全連接前饋神經網路（feedforward neural network），是本專案基線架構。
Loss Function		訓練時用來衡量「網路輸出有多差」的數值目標。PINN 的 loss function 由三部分組成：PDE residual、boundary condition error、initial condition error。
Activation Function		神經元內部的非線性函數（如 tanh、ReLU、sin）。選擇不當會影響 PINN 對高頻特徵的捕捉能力。
Residual Connection		跳層連結（skip connection），讓梯度可以直接回傳到較淺的層，防止 vanishing gradient。
Vanishing Gradient		深層網路訓練時梯度越傳越小，導致淺層的權重幾乎無法更新的現象。層數超過 8 層的 tanh MLP 特別容易發生。
PINN 核心		
Physics-Informed Neural Network	PINN	將物理方程式（PDE）嵌入 loss function 的神經網路，不需要標記量測資料即可求解流場。
Partial Differential Equation	PDE	包含多個偏導數的方程式。Navier-Stokes 就是一組 PDE，PINN 的 loss function 就是 PDE 的殘差（residual）。
Collocation Points		PINN 在訓練時用來評估 PDE residual 的散佈座標點 (x, y, t)，取代 CFD 的 mesh 格子。

術語	縮寫	說明
Residual		PDE 方程式在某個點上「未被滿足的程度」。Residual 越接近零，代表網路在該點越符合物理。
Forward Problem		給定 PDE 和所有物理參數（如黏度 μ ），求解流場 (u, v, p) 。這是基線唯一能做的任務。
Inverse Problem		給定少量流場量測，同時重建完整流場並反推未知物理參數（如黏度 μ ）。PINN 可以自然支援。
本專案採用的技術		
Fourier Feature Encoding		在輸入進入 MLP 前，先用正弦/餘弦函數把座標映射到高維空間，讓網路能學習高頻函數。
Residual-Based Attention	RBA	根據各個 collocation point 的 PDE residual 大小，自動分配 loss 權重，取代手動調整的固定係數。
Causal Training		強制 PINN 優先把早期時間步（小 t ）學好，再挑戰後期時間步，反映物理因果性（causality）。
Residual-based Adaptive Distribution	RAD	自適應 collocation point 採樣策略：在 PDE residual 最大的區域自動加密取樣點。
Latin Hypercube Sampling	LHS	一種均勻覆蓋多維參數空間的隨機採樣方法，是本專案基線的 collocation point 生成方式。
Ablation Study		系統性地移除或替換模型中的某個組件，以量化該組件對整體性能的貢獻。

1. 什麼是 PINN？

傳統 CFD 怎麼算流場？

想像你要預測水流繞過圓柱後的樣子。傳統 CFD（如 Fluent、OpenFOAM）的做法是把整個空間切成幾十萬個格子（mesh），再在每個格子上求解 Navier-Stokes equations。這樣做很準，但要花幾小時到幾天，還需要有人手動建網格。

PINN 換了一個思路

PINN 不用 mesh。我們改用一個神經網路，讓它學會「任意座標 (x, y, t) 對應的速度 (u, v) 和壓力 p 」。訓練時的 loss function 直接就是 PDE 方程式的殘差——網路不是在 fit 資料，是在滿足物理定律。訓練點只是座標，不需要任何量測標記。

我們的問題：Kármán Vortex Street ($Re = 100$)

我們模擬的是二維不可壓縮層流繞圓柱，Reynolds number $Re = 100$ 。在這個條件下，圓柱後方會週期性產生交替脫落的漩渦，形成 Kármán vortex street。Schäfer-Turek 1996 有這個問題的公開 reference 數值（Cd、Cl、Strouhal number），我們的成果可以直接對比。

傳統 CFD（有限元素法）

PINN（本專案方法）




圖 1：傳統 CFD 網格（左）vs. PINN 散佈座標點 + 神經網路（右）

核心思路總結

Navier-Stokes 說：速度場和壓力場在每個點都必須滿足質量和動量守恆。PINN 把這件事翻譯成一個可微分的 loss term，和 boundary/initial condition 的誤差一起最小化。網路找到一個函數 $(x,y,t) \rightarrow (u,v,p)$ ，讓幾萬個 collocation points 上的 PDE residual 幾乎歸零——這就是整個方法的核心。

2. 目前方法的弱點

Repo 裡現有的 Phase 1 程式碼可以跑、可以出圖，是個不錯的起點。但如果要在 Schäfer-Turek 上拿到可信的數字，或在 Demo Day 拿出有說服力的比較，以下四個問題繞不過去。

△ A：架構過時

使用 2018 年的純 tanh MLP，沒有 residual connections、沒有 adaptive activation functions。深度超過 8 層後發生 vanishing gradient，精度無法進一步提升。

△ B：Loss 權重靠猜

PDE residual、boundary condition、initial condition 三項 loss 的權重（目前為 2.0、5.0 等）是手動調出來的，換一個問題就要重調，沒有理論依據。

△ C：Collocation Points 採樣是手動的

目前用 Latin Hypercube Sampling (LHS) 隨機採樣，再人工在圓柱附近加密一個矩形區域。wake 區域採樣不足，PDE residual 偏高，但訓練資源浪費在流場均勻區。

△ D：只能做 Forward Problem

基線只能「給定 PDE + 物理參數 → 求解流場」。無法做 inverse problem：給定少量量測點，反推未知物理參數（如黏度 ν ）。



圖 2：四個弱點指向基線 pipeline

3. 我們的提案

四條 Workstream 各自對應一個弱點，彼此獨立開發，Day 7 合併成一個模型。每條由一位隊員主導，開發期間不需要等其他人。

Workstream A 架構升級 — PirateNet (JMLR 2025)

一句話：把過時的 tanh MLP 換成 PirateNet 的 adaptive residual blocks + Fourier Feature Encoding。

為什麼有意義？普通深層 MLP 訓練 PINN 時，靠近圓柱表面的速度梯度變化非常劇烈，平滑的 activation function 難以捕捉這些高頻特徵。PirateNet 在輸入端先做 Fourier Feature Encoding (Tancik et al., 2020)，讓網路「看得見」高頻變化；residual connections 則讓梯度在深層網路中暢通無阻，解決 vanishing gradient。

核心技術

論文年份

PirateNet adaptive residual blocks、Fourier Feature Encoding Wang et al., JMLR 2025 | Tancik et al., NeurIPS 2020

預期成果 → 消融實驗對比表 (MLP vs PirateNet) + 訓練誤差熱圖 MP4

Workstream B 訓練策略 — RBA 注意力 + Causal Training (CMAME 2024)

一句話：用 RBA 自動調整 loss 權重，用 causal training 讓網路先學好早期時間步再挑戰後期。

為什麼有意義？Kármán vortex street 是一個時間演化現象：t=0 的 initial condition 決定了 t=1 的流場，t=1 又決定了 t=2。如果強迫網路同時學好所有時間步，它往往會把所有時間的 vorticity 「平均」成一個靜止的圓形，Kármán vortex street 特徵消失。Causal training 解決這個問題；RBA 則自動找出哪些 collocation points 的 PDE residual 最大並加重 loss 懲罰。

核心技術

Residual-Based Attention (RBA)、causal temporal weighting

論文年份

Anagnostopoulos et al., CMAME 2024 | Wang et al., CMAME 2024

預期成果 → RBA 權重熱圖 MP4 + 「有 vs 無 causal」渦量場對比 GIF (視覺最震撼的成果)

Workstream C 自適應採樣 — RAD (CMAME 2023)

一句話：讓網路自己決定把 collocation points 放在哪裡——PDE residual 最大的地方自動獲得更多採樣。

為什麼有意義？手動在圓柱附近畫加密框，是因為我們已經知道哪裡難——這在真實問題裡根本做不到。RAD 的邏輯是：哪裡 PDE residual 大，就在哪裡多放點。每隔幾百個 iteration 重新採樣一次，wake 區域自然吸引到更多 collocation points，上游均勻區自然稀疏——不需要任何人工介入。

核心技術

論文年份

Residual-based Adaptive Distribution (RAD)、R3 Sampling Wu et al., CMAME 2023 | Daw et al., ICML 2023

預期成果 → 配置點雲遷移動畫：點從均勻分佈慢慢聚集到 wake 區域

Workstream D 逆問題 (Inverse Problem) — Raissi et al. 2019

一句話：給 10 個帶雜訊的速度量測點，讓 PINN 重建完整流場，並反推出未知的流體黏度 μ 。

為什麼有意義？這是整個 Demo 最「讓觀眾眼睛一亮」的部分。傳統 data-driven 模型（如純 CNN）若想做 inverse problem，需要大量已知黏度的 labeled training samples。PINN 不需要：它把未知黏度 μ 當作一個可訓練的 scalar parameter，讓 Navier-Stokes equations 同時約束流場和 μ 。10 個帶雜訊的量測點就夠了。

Forward problem 裡哪些是寫死的已知數？

參數	目前值	D 的處理
μ （動力黏度）	0.02 kg/(m·s)	→ 改成 nn.Parameter，反推目標
U_max（入口最大流速）	1.0 m/s	可選 stretch：與 μ 同時反推
ρ （密度）	1.0 kg/m ³	與 μ 在方程式裡以 μ/ρ 出現，單獨反推冗餘
入口剖面形狀	拋物線（函數形式已知）	假設已知，不在反推範疇
圓柱位置 / 半徑	(0.2, 0.2)，r=0.05 m	幾何已知，需大幅改 data pipeline 才能反推
出口壓力	p = 0	BC 已知，不反推

核心技術


joint optimization（流場 + 物理參數）、sparse measurement reconstruction

論文年份

Raissi, Perdikaris & Karniadakis, JCP 2019

預期成果 → 現場 Jupyter Widget：感測器數量滑桿 → Run → 30 秒顯示完整流場 + 反推黏度值

四條 Workstream 的平行時程



4. 工作分配與時程

DAY	工作內容	平行度	關鍵里程碑
1	環境設定；閱讀各自論文；確認基線能跑；分工細化	4/4 並行	—
2	A：Fourier 編碼原型 B：RBA 初版 C：RAD 採樣迴圈 D：逆問題訓練腳本	4/4 並行	—

DAY	工作內容	平行度	關鍵里程碑
3	各 Workstream 跑通最小可行版本；互相 code review；排除技術風險	4/4 並行	De-risk 檢查點
4	A：PirateNet 完整實作 B：Causal 加權整合 C：RAD 動畫生成 D：Widget 雛型	4/4 並行	—
5	超參數調整；各自生成初版視覺化成果；撰寫實驗記錄	4/4 並行	—
6	各 Workstream 程式碼凍結；準備整合接口；Schäfer-Turek 基準數字確認	4/4 並行	Integration Freeze
7	整合：INT-1（P1+P3，A+C 合併訓練） INT-2（P2+P4，B+D Widget 對接）；解決合併衝突	2×2 分組	—
8	最終 MP4 / GIF 生成；Demo Widget 最終化；投影片完成	4/4 並行	Demo Asset Freeze
8	第 1、2 次彩排（全流程含 Live Demo）；收集回饋並修正	Dry Run ×2	—
9	彩排（含 Live Demo 壓力測試）；最終確認；Demo Day（6/2）	Dry Run ×1	Demo Day

注意：Day 3（de-risk）是最重要的內部檢查點。若有任何 Workstream 在 Day 3 仍無法跑通最小可行版本，需立即升報並調整範疇。

5. 預期成果

ACT 1 問題與基線 說明 Kármán 渦街問題；播放基線渦街動畫；點出四個弱點；建立「為什麼需要改進」的論據。	ACT 2 四條改進軸 每個 Workstream 一張投影片，各配一個「Money Shot」視覺化成果：消融表、RBA 熱圖、點雲遷移動畫、初步逆問題結果。	ACT 3 整合結果 + Live Demo 完整模型的 Schäfer-Turek 驗證表；現場執行逆問題 Widget，觀眾看到黏度從稀疏雜訊中被反推出來。
--	--	--

硬性交付物清單

☐ Kármán 渦街 MP4（Workstream A/B） 觀眾會看到渦流從圓柱後方週期性脫落，形成交替排列的漩渦；改進模型的渦結構比基線更清晰銳利。
☐ RBA 權重熱圖動畫 MP4（Workstream B） 高亮區域顯示 PINN 在哪些點「最努力學習」，渦街尾流會呈現明顯的注意力聚集。
☐ 「有 vs 無 Causal Training」對比 GIF（Workstream B） 左側無 causal 版本流場模糊成一個靜止圓形；右側有 causal 版本清晰展示週期性渦街。
☐ RAD 點雲遷移動畫（Workstream C） collocation points 從均勻分佈慢慢聚集到 wake 區域，展示網路學會了哪裡最難。
☐ 逆問題 Live Jupyter Widget（Workstream D） 給 10 個帶雜訊的速度量測點，按下 Run，30 秒後螢幕上顯示完整重建流場和反推出的黏度值（目標誤差 <10%）。

☐ **Schäfer-Turek 基準驗證表**

對比基線與改進模型在阻力係數、升力係數、渦脫頻率等標準指標上的數值，量化提升幅度。

☐ **最終報告 (LaTeX PDF)**

含方法推導、實驗設定、結果表格、相關文獻引用。格式符合課程規定。

6. 視覺化交付規格

視覺化是這次 Demo 的核心競爭力。下面列出每個成果的格式要求、使用工具，以及 6/2 當天的播放方式。**所有成果必須在沒有網路的環境下可播放或執行。**

成果	負責	格式	工具	DEMO DAY 播放
Kármán 渦街動畫	A / B	MP4 · 1080p · 30fps	matplotlib.animation + FFMpegWriter	投影片內嵌，直接播放
訓練誤差熱圖	A	MP4 · 1080p · 30fps	matplotlib.animation + FFMpegWriter	投影片內嵌，直接播放
RBA 權重熱圖動畫	B	MP4 · 1080p · 30fps	matplotlib.animation + FFMpegWriter	投影片內嵌，直接播放
有 vs 無 Causal 對比	B	GIF · side-by-side	imageio + pillow (ffmpeg 備援)	投影片內嵌，直接播放
RAD 點雲遷移動畫	C	MP4 · 1080p · 30fps	matplotlib.animation + FFMpegWriter	投影片內嵌，直接播放
Plotly 互動點分佈	C	HTML (單一檔案)	plotly (export to standalone HTML)	瀏覽器直接開啟 .html，離線可用
逆問題 Live Widget	D	Jupyter Notebook	ipywidgets + matplotlib	Jupyter 本地跑，展示電腦預先安裝環境
逆問題 Plotly HTML 備援	D	HTML (單一檔案)	plotly (pre-baked snapshots)	Widget 若當場失敗，立即切換此頁

工具安裝確認 (Day 1 前必做)

- **ffmpeg**：執行 `ffmpeg -version`；若找不到，執行 `brew install ffmpeg` (macOS) 或對應套件管理器。這是 MP4 輸出的硬性依賴，沒裝就無法輸出任何動畫。
- **Python 套件**：`pip install matplotlib imageio pillow plotly ipywidgets`；在展示電腦上跑一次確認不報錯。
- **Jupyter Widget 展示前**：執行 `jupyter nbextension enable --py widgetsnbextension (classic notebook)` 或確認 JupyterLab 有 `widgetsnbextension` 啟用。

Demo Day 技術備援原則

每個互動成果都必須有一個靜態備援：Widget 掛掉切 Plotly HTML；MP4 播不了切截圖投影片。Day 8 (6/1) 成果凍結時，每人同時確認備援版本可用。

6.5. 目前進度與最新結果（Current Progress）


以下是目前 PyTorch PINN baseline 的最新訓練狀態與可直接展示的輸出圖檔。


Training status snapshot

CASE	CHECKPOINT	CURRENT STATUS	BEST LOSS
Phase 1 vanilla Re=10 baseline	results/phase1_reproduction/vanilla_pytorch/checkpoints/best.pt	已續跑到約 20k Adam iterations , loss 已進入緩慢改善區間。	0.0383796319 @ iter 20130
Phase 1 strict SciPy reproduction	results/phase1_reproduction/strict_reproduce_scipy/checkpoints/best.pt	已完成 10k Adam iterations , 最新 field frames 與 animation 已重新產生。	0.0257013496 @ iter 9954

Baseline convergence and field comparison

Phase 1 baseline artifacts are now archived under phase-scoped results directories. The plots below point to the organized Re=10 reproduction outputs.







Phase 1 baseline field comparison —
results/phase1_reproduction/vanilla_pytorch/benchmarks/latest_lbfgs/field_comparison_t0p50.png

Unsteady loss convergence

Unsteady baseline 從初始 loss 約 10.38 降到 final loss 0.0280522108，最佳 checkpoint 出現在 iteration 9954。目前可用下面兩張圖檢查 raw 與 smoothed convergence。




Phase 1 baseline L2 over time —
results/phase1_reproduction/vanilla_pytorch/benchmarks/latest_lbfgs/l2_vs_time.png




Strict reproduction L2 over time —
[results/phase1_reproduction/strict_reproduce_scipy/benchmarks/final/l2_vs_time.png](#)

Unsteady pressure trace and field animation

The pressure trace samples the leading point used by the existing unsteady post-processing code ($x = 0.15$, $y = 0.20$) across $t \in [0, 0.5]$. The animation below is generated from 51 predicted field frames using the best unsteady checkpoint.



Leading-point pressure trace — [results/phase1_reproduction/vanilla_pytorch/figures/front_pressure.png](#)



Original reference unsteady animation —
results/reference/pinn_laminar_flow_original/unsteady/uvp_animation.gif

7. 參考資料

所有引用論文一覽，依 Workstream 分組

- [1] Raissi, M., Perdikaris, P., & Karniadakis, G. E. "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations." *Journal of Computational Physics*, 378, 686–707, 2019.

PINN 原始論文，確立了「以 PDE 殘差為損失」的基本框架，也是逆問題應用的奠基之作。

- [2] Rao, C., Sun, H., & Liu, Y. "Physics-informed deep learning for incompressible laminar flows." *Theoretical and Applied Mechanics Letters*, 10(3), 207–212, 2020.

本專案基線實作的直接來源，將 PINN 應用於不可壓縮層流 Navier-Stokes 求解。

- [3] Wang, S., Sankaran, S., & Perdikaris, P. "Respecting causality for training physics-informed neural networks." *Computer Methods in Applied Mechanics and Engineering*, 421, 116813, 2024.
- Workstream B 核心：因果時間加權訓練策略，解決 PINN 在時間演化問題中渦流「抹平」的問題。
-
- [4] Anagnostopoulos, S. J., Toscano, J. D., Stergiopoulos, N., & Karniadakis, G. E. "Residual-based attention in physics-informed neural networks." *Computer Methods in Applied Mechanics and Engineering*, 421, 116805, 2024.
- Workstream B 核心：RBA 自動調整各點損失權重，無需人工設定 loss 比例常數。
-
- [5] Wu, C., Zhu, M., Tan, Q., Kartha, Y., & Lu, L. "A comprehensive study of non-adaptive and residual-based adaptive sampling for physics-informed neural networks." *Computer Methods in Applied Mechanics and Engineering*, 403, 115671, 2023.
- Workstream C 核心：系統性比較各種自適應採樣策略，RAD 方法在多個測試問題上表現最佳。
-
- [6] Daw, A., Bu, J., Wang, S., Perdikaris, P., & Karpatne, A. "Mitigating Propagation Failures in Physics-Informed Neural Networks Using Retain-Resample-Release (R3) Sampling." *Proceedings of the 40th ICML*, 2023.
- Workstream C 補充：R3 採樣策略，專門解決 PINN 訓練中因果傳播失敗導致的誤差積累問題。
-
- [7] Wang, S., Li, B., Chen, Y., & Perdikaris, P. "PirateNets: Physics-informed Deep Learning with Residual Adaptive Networks." *Journal of Machine Learning Research*, 25(402), 1-51, 2025.
- Workstream A 核心：PirateNet 架構，透過自適應殘差塊大幅改善深層 PINN 的訓練穩定性與精度。
-
- [8] Schäfer, M., Turek, S., Durst, F., Krause, E., & Rannacher, R. "Benchmark Computations of Laminar Flow Around a Cylinder." *Flow Simulation with High-Performance Computers II*, NNFM 48, 547-566, 1996.
- 圓柱流的標準基準測試，提供阻力係數、升力係數、渦脫頻率的參考值，供最終結果量化驗證。
-
- [9] Tancik, M., Srinivasan, P. P., Mildenhall, B., Fridovich-Keil, S., et al. "Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains." *NeurIPS*, 33, 2020.
- Workstream A 基礎：Fourier 特徵映射，讓神經網路能夠捕捉低維空間中的高頻函數（如圓柱附近的速度梯度）。
-